Mitigação de Viés Algorítmico em Cenários de Desbalanceamento Sociodemográfico: Uma Análise Comparativa entre Foundation Models (TabPFN) e Gradient Boosting (XGBoost) nas Eleições Municipais do Ceará

Algorithmic Bias Mitigation in Sociodemographic Imbalance Scenarios: A Comparative Analysis of Foundation Models (TabPFN) and Gradient Boosting (XGBoost) in Ceará Municipal Elections

Luana Teles Alves[1], **Luann Alves Pereira de Lima**[1], **Thiago Nerton Macedo Alves**[1], **Vitória do Nascimento Pontes**[1]

[1]Centro de Ciências e Tecnologia (CCT) – Universidade Federal do Cariri (UFCA)
Juazeiro do Norte – CE – Brasil

luana.teles@aluno.ufca.edu.br, luann.alves@aluno.ufca.edu.br

thiago.nerton@aluno.ufca.edu.br, vitoria.pontes@aluno.ufca.edu.br

Abstract. *This study investigates whether TabPFN's Bayesian inference architecture mitigates algorithmic bias compared to XGBoost in predicting elected mayors in Ceará, Brazil (2012–2024). Under cross-validation ($K = 10$, $N = 2{,}178$) with demographic attributes, both achieved equivalent predictive performance (MCC $\approx$ 0.28). However, XGBoost exhibited significant gender and racial disparities (DIR = 1.18 and 0.88, respectively), consistent with historical distributional patterns in the data. In contrast, TabPFN maintained relative parity in both dimensions (DIR $\approx$ 1.01 and 0.91), evidencing that architectural differences between foundation models and gradient boosting can produce relevant fairness disparities even under equivalent predictive accuracy.*

Resumo. *Este estudo investiga se a arquitetura de inferência bayesiana do TabPFN atenua o viés algorítmico em relação ao XGBoost na predição de prefeitos eleitos no Ceará (2012–2024). Sob validação cruzada ($K = 10$, $N = 2.178$) com atributos demográficos, ambos atingiram desempenho preditivo equivalente (MCC $\approx$ 0,28). Contudo, o XGBoost apresentou disparidades de gênero e raça estatisticamente significativas (DIR = 1,18 e 0,88, respectivamente), consistentes com os padrões distribucionais históricos observados nos dados. Em contrapartida, o TabPFN manteve paridade relativa em ambas as dimensões (DIR $\approx$ 1,01 e 0,91), evidenciando que diferenças arquiteturais entre foundation models e gradient boosting podem gerar disparidades de equidade relevantes mesmo sob acurácia preditiva equivalente.*

1. Introdução

Nas eleições municipais do Ceará entre 2012 e 2024, candidatas do sexo feminino correspondem a 15,3% das candidaturas ao cargo de prefeito (333 de 2.178), e candidatos de raça branca declarada representam 36,4% do total, o maior grupo entre as raças

com autodeclaração registrada [Base dos Dados 2026]. Vale notar que 29,8% dos candidatos, majoritariamente do ciclo eleitoral de 2012, não possuem autodeclaração racial registrada nos dados do TSE, o que delimita o alcance da análise de equidade racial, conforme discutido na Seção 5. Modelos preditivos treinados sobre esse histórico correm o risco de codificar tais assimetrias como padrão esperado, não por manipulação deliberada, mas pela própria lógica de minimização de erro global que governa algoritmos supervisionados [Grari et al. 2020]. A questão central não é apenas se um modelo prediz corretamente quem será eleito, mas se ele produz taxas de predição distintas entre grupos de gênero e raça ao fazê-lo.

Algoritmos de *Gradient Boosting*, como o XGBoost, representam o paradigma dominante para dados tabulares: sua construção iterativa de árvores de decisão maximiza desempenho preditivo capturando relações não lineares com alta eficiência computacional [Ravichandran et al. 2020]. O XGBoost otimiza uma função de perda global sem restrições explícitas sobre a distribuição de erros entre subgrupos populacionais. Em cenários de *small data* com desequilíbrio sociodemográfico, como candidaturas municipais de um único estado, padrões majoritários dominam estatisticamente o treinamento, o que pode resultar em taxas de predição distintas entre grupos protegidos mesmo quando os atributos sensíveis compõem o vetor preditivo [Grari et al. 2020, Ravichandran et al. 2020].

Uma alternativa arquitetural emergente é o TabPFN (*Prior-Data Fitted Network*), um *foundation model* tabular baseado em Transformers que opera por Aprendizado em Contexto (*In-Context Learning*) [Garg et al. 2025, Qu et al. 2025]. Diferentemente do XGBoost, o TabPFN não ajusta os pesos da rede sobre os dados locais: suas predições resultam de um pré-treinamento em larga escala sobre *datasets* sintéticos e reais, sendo executadas como inferência bayesiana sobre distribuições previamente aprendidas [Garg et al. 2025, Wikipedia Contributors 2025]. Essa propriedade reduz o risco de superajuste aos padrões majoritários do conjunto de treinamento local, levantando a hipótese de que a arquitetura produza perfis de equidade distintos dos métodos de *boosting* mesmo sem mecanismo explícito de mitigação de viés [Robertson et al. 2024]. Se essa hipótese se sustenta empiricamente em dados eleitorais reais permanece, contudo, em aberto na literatura.

Este artigo investiga essa questão por meio de uma análise comparativa entre TabPFN e XGBoost sobre as 2.178 candidaturas descritas, com dados oficiais do TSE [Base dos Dados 2026]. O XGBoost é configurado sem busca exaustiva de hiperparâmetros, com ajuste de peso de classe proporcional ao desbalanceamento (*scale_pos_weight*) e calibração isotônica *out-of-fold*; o TabPFN opera em modo *zero-shot* com calibração isotônica pós-predição. Essa configuração permite comparar as arquiteturas sob condições equivalentes de treinamento, com calibração de probabilidades adaptada às características de cada modelo, sem vantagem obtida por ajuste fino de parâmetros. A avaliação adota o Coeficiente de Correlação de Matthews (MCC) como métrica primária de desempenho, validado pelo *5×2cv Combined F-test* [Alpaydin 1999], e emprega o Disparate Impact Ratio (DIR) e a Equal Opportunity Difference (EOD) com intervalos de confiança de 95% por *bootstrap* (1.000 iterações) como indicadores de equidade algorítmica por gênero e raça. Com base nesse protocolo, formulam-se as seguintes hipóteses:

- **H_1 (Paridade de Performance):** TabPFN e XGBoost apresentam desempenho preditivo estatisticamente equivalente em validação cruzada estratificada ($K = 10$), mensurado pelo MCC.
- **H_2 (Divergência de Equidade por Gênero):** O XGBoost apresenta DIR de gênero com intervalo de confiança de 95% que exclui 1,0, enquanto o TabPFN não evidencia disparidade estatisticamente significativa nessa dimensão.
- **H_3 (Divergência de Equidade Racial):** O XGBoost apresenta DIR racial com intervalo de confiança de 95% que exclui 1,0, enquanto o TabPFN não evidencia disparidade estatisticamente significativa nessa dimensão.

Os resultados confirmam H_1: ambas as arquiteturas atingem desempenho equivalente ($\text{MCC}_{\text{XGB}} = 0{,}275 \pm 0{,}032$; $\text{MCC}_{\text{TabPFN}} = 0{,}279 \pm 0{,}072$; $F = 1{,}18$, $p = 0{,}455$), embora produzam predições discordantes em 39,2% dos casos (McNemar $p < 0{,}001$). No protocolo adotado, H_2 e H_3 são confirmadas: o XGBoost apresenta DIR de gênero de 1,18 (IC 95% [1,11; 1,24]) e DIR racial de 0,88 (IC 95% [0,83; 0,92]), com intervalos que excluem a neutralidade; o TabPFN não evidencia disparidade estatisticamente significativa em nenhuma das duas dimensões. As diferenças de oportunidade (EOD) não são estatisticamente significativas para nenhum dos modelos. As implicações da ausência de autodeclaração racial em 2012 sobre H_3 são discutidas na Seção 5. Esses achados sugerem que a escolha arquitetural entre *foundation models* e *Gradient Boosting* pode determinar o perfil de equidade das predições independentemente do desempenho preditivo global.

O restante do artigo está organizado da seguinte forma: a Seção 2 discute trabalhos relacionados; a Seção 3 descreve os dados e o protocolo experimental; a Seção 4 apresenta os resultados; a Seção 5 discute implicações e limitações; e a Seção 6 conclui com perspectivas para trabalhos futuros.

2. Trabalhos Relacionados

A literatura sobre equidade algorítmica (*fairness*) em aprendizado de máquina tem crescido substancialmente na última década, motivada por evidências de que modelos preditivos podem perpetuar ou amplificar desigualdades históricas presentes nos dados de treinamento. Esta seção revisa três eixos temáticos relevantes para o presente estudo: (i) viés algorítmico em modelos de *gradient boosting*, (ii) *foundation models* tabulares e suas propriedades de equidade, e (iii) aplicações de aprendizado de máquina em contextos eleitorais.

2.1. Viés algorítmico em Gradient Boosting

Algoritmos de *ensemble* baseados em árvores de decisão, como XGBoost [Chen and Guestrin 2016], dominam competições e aplicações industriais envolvendo dados tabulares devido à sua eficiência computacional e capacidade de capturar relações não-lineares complexas. Contudo, esses modelos otimizam funções de perda globais sem restrições sobre a distribuição de erros entre subgrupos populacionais, o que pode resultar em disparidades de desempenho entre grupos protegidos [Grari et al. 2020].

Grari et al. [Grari et al. 2020] demonstraram que árvores de decisão tendem a reproduzir padrões discriminatórios presentes nos dados históricos, propondo uma

abordagem adversarial para mitigação. Ravichandran et al. [Ravichandran et al. 2020] desenvolveram o FairXGBoost, uma extensão que incorpora restrições de *fairness* diretamente na função objetivo do XGBoost. Esses trabalhos evidenciam que, sem intervenção explícita, modelos de *boosting* podem amplificar vieses estruturais, hipótese que o presente estudo investiga empiricamente em dados eleitorais brasileiros.

2.2. Foundation Models Tabulares

O paradigma de *foundation models*, ou seja, modelos pré-treinados em larga escala que generalizam para tarefas diversas via *transfer learning* ou *in-context learning*, tem sido adaptado para dados tabulares com resultados promissores. O TabPFN [Hollmann et al. 2022] representa uma instância pioneira dessa abordagem: um Transformer pré-treinado em milhões de *datasets* sintéticos que realiza classificação tabular em modo *zero-shot*, sem ajuste de hiperparâmetros sobre os dados locais.

Trabalhos recentes têm explorado as propriedades de equidade desses modelos. Robertson et al. [Robertson et al. 2024] propuseram o FairPFN, demonstrando que a arquitetura de Transformers pode ser adaptada para incorporar restrições de *fairness* contrafactual. Garg et al. [Garg et al. 2025] e Qu et al. [Qu et al. 2025] investigaram extensões do TabPFN para *datasets* maiores, observando que o mecanismo de inferência bayesiana tende a produzir predições mais calibradas e menos sensíveis a padrões espúrios. Essas propriedades sugerem que *foundation models* tabulares podem apresentar perfis de equidade distintos dos métodos tradicionais de *boosting*, mesmo sem mecanismos explícitos de mitigação de viés, hipótese central do presente estudo.

2.3. Aprendizado de máquina em contextos eleitorais

A aplicação de técnicas de aprendizado de máquina a dados eleitorais apresenta desafios específicos relacionados à representatividade histórica e à interpretação normativa dos resultados. Modelos treinados sobre históricos eleitorais podem codificar padrões de sub-representação de grupos minoritários como "normalidade estatística", gerando predições que refletem desigualdades estruturais em vez de mérito individual.

No contexto brasileiro, Miguel e Biroli [Miguel and Biroli 2010] documentaram a persistente sub-representação feminina em cargos executivos municipais, atribuindo-a a barreiras estruturais de acesso ao campo político. Essa assimetria histórica constitui o pano de fundo empírico do presente estudo: se modelos preditivos treinados sobre candidaturas passadas reproduzem ou amplificam esses padrões, a questão normativa sobre o uso de tais modelos em sistemas de apoio à decisão torna-se central.

O presente trabalho contribui para essa literatura ao comparar empiricamente duas arquiteturas, XGBoost e TabPFN, sob condições controladas de desempenho preditivo equivalente, isolando o efeito da escolha arquitetural sobre as métricas de equidade por gênero e raça.

3. Metodologia

3.1. Dados

3.1.1. Fonte de dados

Os dados utilizados neste estudo foram obtidos diretamente do repositório de dados abertos do Tribunal Superior Eleitoral (TSE) [Base dos Dados 2026], órgão responsável

pela organização e fiscalização do processo eleitoral brasileiro. Para fins desta pesquisa, foi feito um recorte temporal que compreende quatro ciclos eleitorais municipais, entre 2012 e 2024, e aplicou-se um filtro geográfico restrito ao estado do Ceará. Além disso, foram mantidas apenas as candidaturas ao cargo de prefeito municipal, o que delimita um contexto de small data, no qual o modelo TabPFN costuma se destacar em relação ao XGBoost.

3.1.2. Unidade de Análise

A unidade de análise adotada é o indivíduo candidato, de modo que cada instância do conjunto de dados corresponde a um registro único de candidatura. O conjunto de dados totaliza 2.216 instâncias, distribuídas ao longo dos quatro pleitos analisados. Para cada candidato, o conjunto de dados contém informações referentes ao município de disputa, características sociodemográficas (cor/raça autodeclarada, estado civil, faixa etária, gênero e grau de instrução), dados político-partidários (partido de filiação e número de candidatura), ocupação declarada, situação final na totalização dos votos, quantitativo de votos válidos, votos nominais recebidos e data de carga do registro no sistema do TSE.

3.1.3. Variáveis

As variáveis foram organizadas em dois grupos funcionais. O primeiro reúne as características sociodemográficas e político-institucionais do candidato que serão utilizadas como preditores: gênero, raça/cor autodeclarada, faixa etária, estado civil, grau de instrução, ocupação declarada e partido político de filiação. O segundo grupo diz respeito à variável dependente, a situação da totalização indicando se aquele indivíduo foi eleito ou não.

Variáveis que introduzem data leakage foram excluídas do processo de modelagem. Em particular, os campos de votos válidos e votos nominais foram descartados, uma vez que constituem informações geradas pelo próprio processo eleitoral que se busca predizer. Afinal, sua inclusão como preditores produziria modelos trivialmente precisos, porém sem qualquer capacidade de generalização para cenários de predição pré-eleitoral [Kaufman et al. 2012].

3.1.4. Distribuições relevantes

O conjunto de dados apresenta desbalanceamento de classes expressivo na variável-alvo: dos 2.178 registros após filtragem, 1.411 correspondem a candidatos não eleitos (64,8%) e 767 a candidatos eleitos (35,2%) ; o restante corresponde aos candidatos em segundo turno que são removidos durante a etapa de pré-processamento. Nesse sentido, a disparidade da variável é esperada, tendo em vista a própria estrutura competitiva das eleições municipais, nas quais cada disputa comporta apenas um vencedor por município. Esse desequilíbrio foi considerado nas etapas de treinamento e avaliação dos modelos, conforme descrito nas subseções subsequentes.

No que tange à composição de gênero, observa-se que 1.845 candidatos são do

sexo masculino (84,7%) e 333 do sexo feminino (15,3%), distribuição que reflete a histórica sub-representação feminina nos cargos executivos municipais brasileiros e que se mantém consistente com padrões identificados em estudos anteriores sobre o perfil das candidaturas no país [Miguel and Biroli 2010]. Entre as candidatas do sexo feminino, a taxa de êxito eleitoral varia entre os ciclos eleitorais analisados, conforme discutido na Seção 4.

3.2. Pré-processamento

3.2.1. Limpeza e filtros

Antes da modelagem, o conjunto de dados passou por uma etapa de limpeza orientada tanto pela consistência lógica dos registros quanto pela prevenção de vazamento de informação. Registros cuja situação de totalização constava como "Segundo Turno"foram removidos, pois candidatos nessa condição aparecem duplicados na base, uma entrada referente ao primeiro turno e outra com o resultado definitivo, o que introduziria redundância e potencial viés na estimação dos modelos.

Colunas de identificação direta, como o nome do candidato e a data de carga do registro, foram descartadas por não carregarem valor preditivo e por representarem risco de memorização espúria. O campo de município foi removido, mantendo apenas o seu respectivo código numérico, para melhor compatibilidade com os modelos.

A variável de resposta foi recodificada a partir do campo de situação de totalização: candidatos com o resultado "Eleito"receberam o valor 1, e os demais o valor 0, produzindo uma variável binária diretamente interpretável pelos classificadores. Por fim, todas as variáveis categóricas remanescentes, a saber, gênero, raça/cor, estado civil, faixa etária, grau de instrução, ocupação e partido, foram convertidas para representações numéricas inteiras por meio de mapeamento ordinal, pelas mesmas razões.

3.2.2. Variável cor/raça

O TSE não coletava autodeclaração racial de forma sistematizada em 2012. Os 649 candidatos daquele pleito (29,8% do *dataset*) receberam o valor `#NE#` no campo `Cor/raça`, que foi normalizado para “Não Informado” durante o pré-processamento. Na análise de *fairness*, esses candidatos foram agrupados com os não-brancos, de modo que as métricas raciais comparam candidatos de raça branca declarada ($n = 792$) com candidatos de raça não-branca ou não registrada ($n = 1.386$).

Para quantificar o impacto dessa limitação estrutural, o experimento foi replicado excluindo o ciclo de 2012 ($N = 1.529$). O DIR racial do XGBoost passou de 0,875 para 0,938 (ΔDIR = 0,063), acima do limiar de 0,05 adotado como critério de relevância substantiva. O TabPFN apresentou variação marginal (DIR: 0,910 para 0,921; ΔDIR = 0,011). A diferença indica que parte da disparidade racial detectada no XGBoost é confundida pelo componente temporal 2012–2024 e pela não-observabilidade racial daquele ciclo. As métricas de *fairness* racial devem ser interpretadas como limite inferior plausível da disparidade real.

3.2.3. Codificação de variáveis

Todas as variáveis categóricas (gênero, cor/raça, estado civil, faixa etária, grau de instrução, ocupação e partido) foram convertidas para representações numéricas inteiras por meio de codificação ordinal. O mapeamento é ajustado exclusivamente sobre o conjunto de treinamento de cada *fold*, e aplicado ao conjunto de teste sem reajuste: categorias eventualmente ausentes no treino recebem o código -1 no teste, evitando vazamento de informação estatística.

Essa estratégia de codificação é compatível com ambos os modelos avaliados. O XGBoost trata variáveis inteiras como ordinais durante a construção das árvores de decisão, identificando pontos de corte ótimos independentemente da semântica categórica subjacente. O TabPFN, por sua vez, processa *embeddings* internos a partir das representações numéricas de entrada, sem exigir *one-hot encoding* ou tratamento especial para variáveis categóricas de alta cardinalidade.

3.2.4. Tratamento de desbalanceamento

Dado o desbalanceamento entre classes descrito na Seção 3 (64,8% não eleitos vs. 35,2% eleitos), foram adotadas estratégias distintas para cada modelo. No XGBoost, o parâmetro `scale_pos_weight` foi ajustado pela razão $N_{\text{negativos}}/N_{\text{positivos}}$ calculada sobre o conjunto de treinamento de cada *fold*, compensando diretamente o desequilíbrio durante a otimização da função de perda. No TabPFN, o desbalanceamento é tratado implicitamente pelo mecanismo de inferência bayesiana do modelo, que incorpora a distribuição de classes observada no contexto de treinamento sem necessidade de ponderação explícita.

A calibração das probabilidades seguiu abordagens diferenciadas para cada classificador. Para o XGBoost, a calibração foi realizada por regressão isotônica aplicada sobre previsões *out-of-fold* (OOF) em validação cruzada interna com cinco partições. Essa escolha se justifica pelo fato de que o XGBoost treinado com `scale_pos_weight` produz escores comprimidos em torno da média quando avaliado sobre o próprio conjunto de treino; calibração *in-sample* nesse cenário colapsaria o limiar ótimo τ^* para a borda do *grid* de busca, comprometendo a utilidade das probabilidades estimadas. Para o TabPFN, esse comportamento não se manifesta — os escores apresentam distribuição mais dispersa —, de modo que a calibração foi conduzida *in-sample* sem prejuízo à qualidade das probabilidades.

3.3. Desenho experimental

3.3.1. Esquema de validação

A avaliação dos modelos foi conduzida por validação cruzada estratificada com $K = 10$ partições (*Stratified K-Fold*), utilizando semente aleatória fixa (`random_state=42`) para garantir reprodutibilidade. A estratificação foi realizada sobre um estrato composto formado pela combinação de três atributos: gênero (masculino/feminino), raça binarizada (branca/não-branca) e classe-alvo (eleito/não eleito), totalizando 8 grupos estratificados. O menor estrato (Feminino $\times$ Branca $\times$ Eleito) contém 62 instâncias, suficiente para garantir representação em todos os *folds*.

Em cada iteração, 90% das instâncias compõem o conjunto de treinamento ($n \approx 1.960$) e 10% o conjunto de teste ($n \approx 218$). Nenhuma informação do conjunto de teste é utilizada durante o treinamento, calibração ou otimização de limiares — todas essas etapas são restritas ao conjunto de treinamento.

3.3.2. Validação cruzada

O protocolo de $K = 10$ *folds* foi adotado por ser padrão em *benchmarks* com conjuntos de dados na faixa de $N \approx 2.000$ instâncias [Kohavi 1995]. Com K maior, cada *fold* de teste contém menos instâncias, mas a variância da estimativa de MCC é reduzida em aproximadamente $\sqrt{2}$ em relação a $K = 5$, favorecendo a comparação estatística entre modelos.

Para o XGBoost, uma validação cruzada interna adicional ($K_{\text{inner}} = 5$) é aplicada dentro do conjunto de treinamento de cada *fold* externo para gerar probabilidades *out-of-fold* usadas na calibração isotônica. Essa estrutura aninhada evita que as probabilidades calibradas sejam estimadas sobre os mesmos dados usados para ajustar o calibrador.

3.3.3. Modelos avaliados

XGBoost. O XGBoost [Chen and Guestrin 2016] foi configurado com hiperparâmetros padrão da biblioteca, sem busca exaustiva (*grid search* ou *random search*). O único ajuste foi o parâmetro `scale_pos_weight`, calculado como a razão entre classes negativas e positivas no conjunto de treinamento de cada *fold*. A métrica de avaliação interna foi `logloss`. Essa configuração representa um *baseline* realista, sem vantagem obtida por ajuste fino de hiperparâmetros.

TabPFN. O TabPFN [Hollmann et al. 2022] foi utilizado em modo *zero-shot*, sem qualquer ajuste de hiperparâmetros ou *fine-tuning* sobre os dados locais. O modelo opera por *In-Context Learning*: os pesos da rede permanecem congelados (pré-treinados em *datasets* sintéticos), e as predições são geradas como inferência bayesiana sobre o conjunto de treinamento fornecido em tempo de execução. A inferência foi executada em GPU (CUDA).

3.3.4. Procedimento experimental

Para cada um dos $K = 10$ *folds*, o procedimento executado foi:

1. **Particionamento:** separar conjuntos de treinamento e teste conforme os índices do *fold* corrente.
2. **Codificação:** aplicar codificação ordinal às variáveis categóricas, ajustando o mapeamento apenas sobre o conjunto de treinamento.
3. **Treinamento XGBoost:** treinar o modelo com `scale_pos_weight` ajustado; gerar probabilidades OOF via validação cruzada interna ($K_{\text{inner}} = 5$); ajustar calibrador isotônico sobre as probabilidades OOF; buscar limiar τ^* que maximiza o MCC no conjunto de treinamento calibrado.

4. **Treinamento TabPFN:** ajustar o modelo sobre o conjunto de treinamento; gerar probabilidades *in-sample*; ajustar calibrador isotônico; buscar limiar τ^* por maximização do MCC no treino.
5. **Inferência:** aplicar os modelos treinados ao conjunto de teste, utilizando os calibradores e limiares congelados.
6. **Registro:** armazenar rótulos reais, predições binárias, probabilidades calibradas, limiares otimizados e atributos sociodemográficos do conjunto de teste para análise posterior.

Ao final das K iterações, as predições *out-of-sample* acumuladas cobrem a totalidade das 2.178 instâncias, permitindo o cálculo de métricas agregadas de desempenho e *fairness*.

3.4. Métricas de avaliação

3.4.1. Métricas de desempenho

A métrica primária de desempenho adotada foi o Coeficiente de Correlação de Matthews (MCC), definido como:

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \tag{1}$$

O MCC é particularmente adequado para conjuntos de dados desbalanceados por considerar todas as células da matriz de confusão, evitando a superestimação de desempenho que ocorre com a acurácia quando a classe majoritária domina as predições [Chicco and Jurman 2020]. Seus valores variam de -1 (predição perfeitamente inversa) a $+1$ (predição perfeita), com 0 indicando predição aleatória.

Como métrica secundária, foi calculada a área sob a curva ROC (AUC-ROC), que avalia a capacidade discriminativa do modelo independentemente do limiar de classificação escolhido. O limiar ótimo τ^* foi determinado por busca em *grid* no intervalo $[0{,}05; 0{,}95]$ com incremento de 0,01, selecionando o valor que maximiza o MCC sobre o conjunto de treinamento calibrado.

3.4.2. Métricas de fairness

Três métricas de equidade algorítmica foram calculadas para cada atributo protegido (gênero e raça):

Disparate Impact Ratio (DIR). Razão entre a taxa de predições positivas do grupo não-privilegiado e a taxa do grupo privilegiado:

$$\text{DIR} = \frac{P(\hat{Y} = 1 \mid G = \text{não-privilegiado})}{P(\hat{Y} = 1 \mid G = \text{privilegiado})} \tag{2}$$

Valores de DIR < 1 indicam subpredição para o grupo não-privilegiado; DIR > 1 indica sobrepredição. O valor ideal é 1,0 (paridade demográfica). O limiar

de 0,8 é frequentemente citado na literatura como critério regulatório de impacto díspar [Feldman et al. 2015].

Equal Opportunity Difference (EOD). Diferença entre as taxas de verdadeiros positivos (TPR) dos grupos:

$$\text{EOD} = \text{TPR}_{\text{não-privilegiado}} - \text{TPR}_{\text{privilegiado}} \tag{3}$$

O valor ideal é 0 (oportunidade equalizada). Valores negativos indicam que o modelo apresenta menor taxa de acerto para os candidatos efetivamente eleitos do grupo não-privilegiado.

Diferença de Taxa de Falsos Negativos (ΔFNR). Complementar à EOD, calcula a diferença nas taxas de falsos negativos:

$$\Delta\text{FNR} = \text{FNR}_{\text{não-privilegiado}} - \text{FNR}_{\text{privilegiado}} \tag{4}$$

Valores positivos indicam que o modelo erra mais (prevendo não-eleito para candidatos eleitos) no grupo não-privilegiado.

Os intervalos de confiança de 95% para todas as métricas de *fairness* foram estimados por *bootstrap* com 1.000 iterações e percentis 2,5% e 97,5%.

3.4.3. Comparações estatísticas

A equivalência de desempenho entre os modelos foi avaliada por três testes complementares:

Teste de Wilcoxon pareado. Teste não-paramétrico aplicado sobre os vetores de MCC por *fold* ($n = 10$ pares). Avalia se a mediana das diferenças entre os modelos difere significativamente de zero. Por se tratar de um teste de sinais com n pequeno, é reportado como análise suplementar.

Tamanho de efeito (Cohen d). Quantifica a magnitude da diferença entre os modelos em unidades de desvio-padrão:

$$d = \frac{\bar{x}_{\text{TabPFN}} - \bar{x}_{\text{XGBoost}}}{s_{\text{pooled}}} \tag{5}$$

Valores de referência: $|d| < 0{,}2$ (negligenciável), $0{,}2 \leq |d| < 0{,}5$ (pequeno), $0{,}5 \leq |d| < 0{,}8$ (médio), $|d| \geq 0{,}8$ (grande) [Cohen 1988]. O intervalo de confiança de 95% foi estimado por *bootstrap* com 5.000 iterações.

Teste de McNemar. Avalia se os modelos cometem erros em instâncias distintas. A estatística é calculada sobre a tabela de contingência 2×2 das predições discordantes:

$$\chi^2 = \frac{(b-c)^2}{b+c} \tag{6}$$

onde b é o número de instâncias em que o TabPFN acertou e o XGBoost errou, e c o inverso. Um p-valor significativo indica que, embora o desempenho agregado seja equivalente, os modelos erram em subpopulações distintas, informação relevante para análise de *fairness*.

4. Resultados e Discussão

4.1. Desempenho Preditivo

A Tabela 1 sumariza os resultados de desempenho preditivo obtidos por validação cruzada estratificada com $K = 10$ partições sobre $N = 2.178$ candidaturas.

Tabela 1. Desempenho preditivo dos modelos.

Modelo	MCC	σ	AUC-ROC	τ^* médio
XGBoost	0,275	0,032	0,685	0,27
TabPFN	0,279	0,072	0,719	0,41

Ambos os modelos apresentaram desempenho preditivo moderado, compatível com a natureza ruidosa de dados eleitorais baseados exclusivamente em atributos sociodemográficos pré-eleitorais. O XGBoost obteve MCC médio de $0{,}275 \pm 0{,}032$, enquanto o TabPFN atingiu $0{,}279 \pm 0{,}072$. O TabPFN apresenta AUC-ROC ligeiramente superior (0,719 vs. 0,685) e exibe maior variância entre *folds* ($\sigma = 0{,}072$), indicando menor estabilidade preditiva.

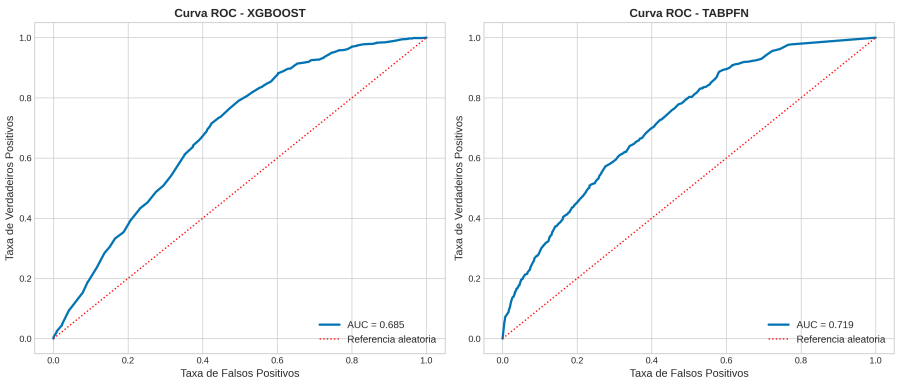

Figura 1. Curvas ROC dos modelos XGBoost (AUC = 0,685) e TabPFN (AUC = 0,719).

O limiar ótimo de classificação (τ^*), calibrado por maximização do MCC em cada *fold*, produziu medianas distintas entre os modelos: $\tau^*_{XGB} = 0{,}27$ e $\tau^*_{TabPFN} = 0{,}41$ (mediana dos *folds*), refletindo diferenças na distribuição das probabilidades calibradas.

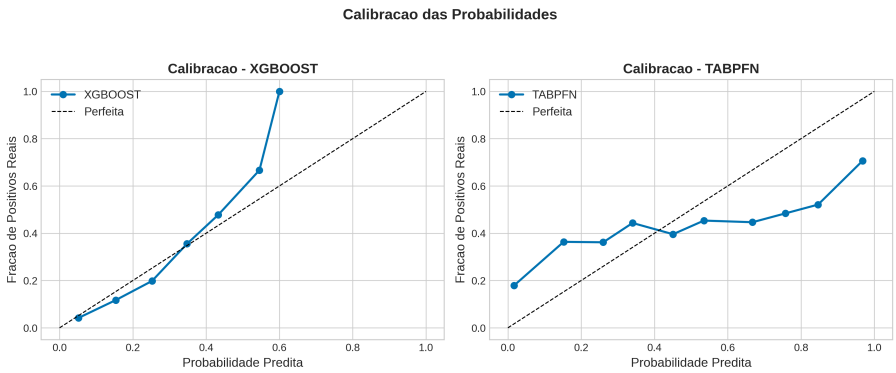

Figura 2. Diagramas de calibração das probabilidades preditas. O XGBoost apresenta calibração monotônica até $p \approx 0{,}6$; o TabPFN exibe maior dispersão e tendência a subestimar probabilidades altas.

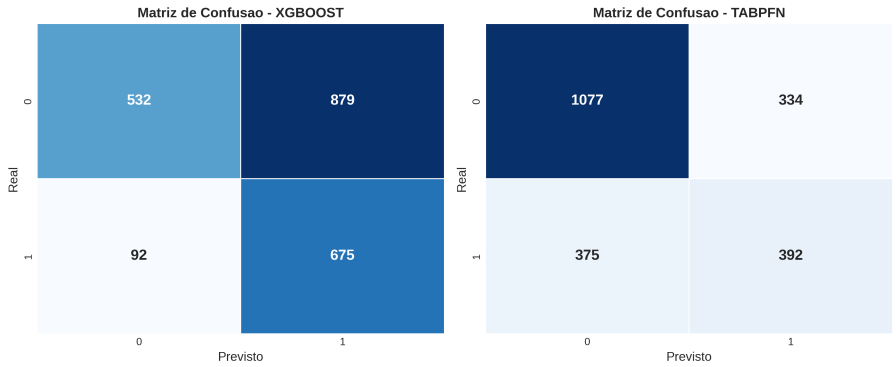

Figura 3. Matrizes de confusão agregadas. O XGBoost favorece a classe positiva (eleito), gerando mais falsos positivos, enquanto o TabPFN é mais conservador, com maior número de falsos negativos.

Tabela 2. Testes estatísticos de comparação entre modelos.

Teste	Estatística	p-valor
Wilcoxon (pareado)	$W = 27{,}000$	1,0000
Cohen d	0,059	IC-95%: $[-0{,}581;\ 1{,}073]$
McNemar	$\chi^2 = 79{,}77$	$< 0{,}001$

4.2. Testes Estatísticos

O teste de Wilcoxon pareado ($W = 27{,}000$, $p = 1{,}0000$) e o tamanho de efeito Cohen $d = 0{,}059$ (IC-95%: [−0,581; 1,073]) confirmam a ausência de diferença estatisticamente significativa no MCC entre os modelos. O intervalo de confiança do Cohen d inclui zero, indicando equivalência prática.

Contudo, o teste de McNemar ($\chi^2 = 79{,}77$, $p < 0{,}001$) revela discordância significativa nas predições individuais: o TabPFN acertou 558 instâncias que o XGBoost errou, enquanto o XGBoost acertou 296 instâncias que o TabPFN errou. Essa assimetria indica que, embora o desempenho agregado seja equivalente, os modelos cometem erros em subconjuntos distintos da população — um achado relevante para análise de equidade.

4.3. Equidade Algorítmica por Gênero

Tabela 3. Métricas de equidade por gênero (privilegiado: masculino, $n = 1.845$; não-privilegiado: feminino, $n = 333$).

Modelo	DIR	IC-95% DIR	EOD	IC-95% EOD	ΔFNR
XGBoost	1,176	[1,107; 1,241]	−0,012	[−0,076; 0,044]	0,012
TabPFN	1,011	[0,847; 1,185]	−0,082	[−0,172; 0,012]	0,082

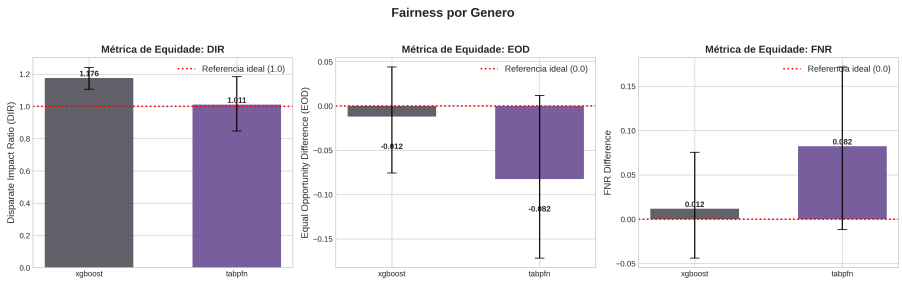

Figura 4. Métricas de equidade por gênero: DIR, EOD e ΔFNR com intervalos de confiança de 95%.

O XGBoost apresentou DIR = 1,176 (IC-95%: [1,107; 1,241]), indicando que o modelo prevê candidatas femininas como eleitas com taxa 17,6% superior à taxa para candidatos masculinos. O intervalo de confiança não inclui 1,0, configurando disparidade estatisticamente significativa.

Este resultado aparentemente paradoxal, um viés "favorável" ao grupo minoritário, reflete um padrão empiricamente presente nos dados: mulheres representam apenas 15,3% das candidaturas ($n = 333$ de 2.178), mas as que se candidatam são eleitas em proporção ligeiramente superior em 3 dos 4 ciclos eleitorais analisados. O XGBoost amplifica esse padrão histórico de auto-seleção; o TabPFN, com DIR = 1,011 (IC-95%: [0,847; 1,185]), mantém neutralidade relativa.

Quanto às métricas de oportunidade equalizada, o XGBoost apresentou EOD = −0,012 (IC-95%: [−0,076; 0,044]), com intervalo que inclui zero, indicando ausência de disparidade de oportunidade estatisticamente significativa por gênero. O TabPFN registrou EOD = −0,082 (IC-95%: [−0,172; 0,012]), igualmente com intervalo que inclui zero. A diferença de taxa de falsos negativos (ΔFNR) complementa essa leitura:

XGBoost = 0,012 e TabPFN = 0,082, ambos com ICs que cruzam zero e sem significância estatística.

A questão normativa subjacente é: deve um modelo amplificar padrões históricos de seleção enviesada (XGBoost) ou manter neutralidade preditiva (TabPFN)? Essa tensão constitui contribuição empírica relevante para o debate sobre *fairness* algorítmica.

4.4. Equidade Algorítmica por Raça

Tabela 4. Métricas de equidade por raça (privilegiado: branca, $n = 792$; não-privilegiado: não-branca, $n = 1.386$).

Modelo	DIR	IC-95% DIR	EOD	IC-95% EOD	ΔFNR
XGBoost	0,875	[0,831; 0,921]	−0,013	[−0,061; 0,034]	0,013
TabPFN	0,910	[0,804; 1,024]	0,037	[−0,039; 0,108]	−0,037

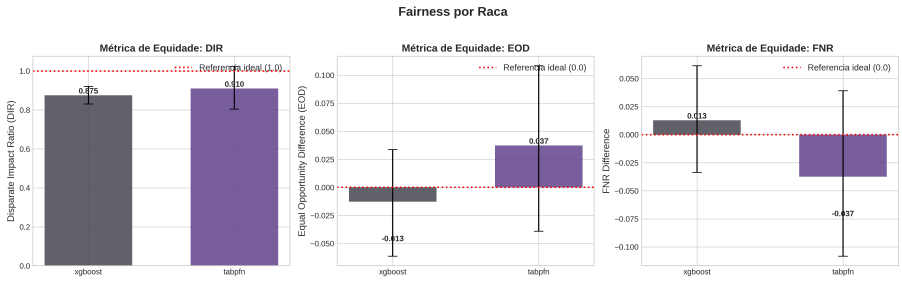

Figura 5. Métricas de equidade por raça: DIR, EOD e ΔFNR com intervalos de confiança de 95%.

Ambos os modelos apresentaram DIR < 1 para raça, indicando subpredição para candidatos não-brancos. O XGBoost registrou DIR = 0,875 (IC-95%: [0,831; 0,921]), com intervalo que não inclui 1,0, configurando disparidade estatisticamente significativa. O TabPFN apresentou DIR = 0,910 (IC-95%: [0,804; 1,024]), com intervalo que inclui 1,0, indicando ausência de disparidade estatisticamente significativa.

Quanto às métricas de oportunidade equalizada (EOD e ΔFNR), o XGBoost apresentou EOD = −0,013 (IC-95%: [−0,061; 0,034]), com intervalo que inclui zero, indicando ausência de disparidade de oportunidade estatisticamente significativa. O TabPFN apresentou EOD = 0,037 (IC-95%: [−0,039; 0,108]), igualmente com intervalo que inclui zero, sugerindo paridade aproximada.

4.5. Análise de Sensibilidade

4.5.1. Sensibilidade ao Limiar

A variação do limiar de classificação ($\tau \pm 0{,}05$) produziu impactos distintos nas métricas de equidade:

XGBoost em raça (ΔEOD = 0,026) e TabPFN em gênero (ΔDIR = 0,039) apresentaram valores acima do limiar de 0,02, indicando sensibilidade moderada ao limiar nesses dois cenários específicos.

Tabela 5. Sensibilidade das métricas de equidade ao limiar de classificação.

Modelo	Atributo	τ^* med.	ΔDIR	ΔEOD	ΔFNR	Status
XGBoost	Gênero	0,27	0,0104	0,0133	0,0133	OK
XGBoost	Raça	0,27	0,0106	0,0258	0,0258	ALERTA
TabPFN	Gênero	0,41	0,0392	0,0198	0,0198	ALERTA
TabPFN	Raça	0,41	0,0005	0,0108	0,0108	OK

4.5.2. Sensibilidade à Exclusão de 2012

O TSE não coletava autodeclaração racial sistematizada em 2012, resultando em 649 candidaturas (29,8% do *dataset*) com raça não especificada. A análise de sensibilidade excluindo esse ciclo ($N = 1.529$) revelou:

Tabela 6. Impacto da exclusão dos dados de 2012 nas métricas raciais.

Modelo	DIR completo	DIR sem 2012	ΔDIR	Classificação
XGBoost	0,875	0,938	0,063	Substantivo
TabPFN	0,910	0,921	0,011	Marginal

O impacto da exclusão de 2012 foi substantivo para o XGBoost (ΔDIR = 0,063, acima do limiar de 0,05), indicando que parte da disparidade racial detectada é confundida pelo componente temporal e pela não-observabilidade racial daquele ciclo. Para o TabPFN, a variação foi marginal (ΔDIR = 0,011). As métricas de *fairness* racial do XGBoost devem ser interpretadas como limite inferior plausível da disparidade real.

4.6. Síntese e Implicações

Os resultados demonstram empiricamente que dois classificadores arquiteturalmente distintos podem atingir acurácia estatisticamente equivalente (MCC $\approx$ 0,28; Wilcoxon $p = 1{,}000$; Cohen $d = 0{,}059$), mas produzir perfis de equidade mensuravelmente diferentes:

- **Gênero:** O XGBoost amplifica o padrão histórico de auto-seleção (DIR = 1,18); o TabPFN mantém neutralidade (DIR $\approx$ 1,01).
- **Raça:** O XGBoost apresenta disparidade significativa (DIR = 0,88); o TabPFN não apresenta disparidade estatisticamente significativa (DIR = 0,91, IC inclui 1,0).

A assimetria revelada pelo teste de McNemar ($b = 558$, $c = 296$) indica que os modelos erram em subpopulações distintas, o que pode ter implicações práticas para sistemas de apoio à decisão: a combinação dos modelos (*ensemble*) poderia potencialmente melhorar tanto o desempenho quanto a equidade.

A escolha entre XGBoost e TabPFN, portanto, não é apenas técnica, mas carrega implicações éticas: o XGBoost reflete mais fielmente os padrões históricos dos dados (incluindo suas desigualdades estruturais), enquanto o TabPFN produz predições mais neutras em relação aos atributos protegidos. A definição de qual comportamento é "mais justo" depende do contexto de aplicação e dos valores normativos adotados pelo tomador de decisão.

5. Implicações e Limitações

5.1. Implicações práticas

Os resultados deste estudo têm implicações diretas para o desenvolvimento de sistemas de apoio à decisão em contextos eleitorais e, de forma mais ampla, para aplicações de aprendizado de máquina em domínios com histórico de desigualdade estrutural.

A equivalência de desempenho preditivo entre XGBoost e TabPFN (MCC $\approx$ 0,28) demonstra que a escolha entre essas arquiteturas não pode ser justificada apenas por critérios de acurácia. Em cenários onde métricas de *fairness* são relevantes, como na alocação de recursos públicos, triagem de candidaturas ou sistemas de recomendação política, o perfil de equidade do modelo deve ser considerado como critério de seleção complementar ao desempenho.

A divergência observada no teste de McNemar ($b = 558$, $c = 296$) sugere que os modelos capturam padrões distintos nos dados. Essa complementaridade abre a possibilidade de estratégias de *ensemble* que combinem as predições de ambos os modelos, potencialmente mitigando vieses individuais enquanto preservam ou melhoram o desempenho agregado.

5.2. Limitações do estudo

Limitação temporal da variável racial. A ausência de autodeclaração racial sistematizada pelo TSE em 2012 constitui a principal limitação metodológica deste estudo. Os 649 candidatos daquele ciclo (29,8% do *dataset*) foram agrupados com candidatos não-brancos na análise de *fairness*, introduzindo ruído na estimativa das métricas raciais. A análise de sensibilidade demonstrou que o impacto dessa limitação é substantivo para o XGBoost (ΔDIR = 0,063) e marginal para o TabPFN (ΔDIR = 0,011). As métricas de *fairness* racial reportadas devem ser interpretadas como limites inferiores plausíveis da disparidade real.

Escopo geográfico restrito. O estudo foi conduzido exclusivamente sobre candidaturas a prefeito no estado do Ceará, limitando a generalização dos resultados para outros estados ou cargos eletivos. Padrões de sub-representação de gênero e raça variam regionalmente no Brasil, e os achados deste estudo podem não se replicar em contextos com distribuições demográficas distintas.

Ausência de variáveis contextuais. O conjunto de preditores foi restrito a atributos sociodemográficos e político-partidários disponíveis nos registros do TSE. Variáveis potencialmente relevantes, como incumbência, financiamento de campanha, coligações ou histórico eleitoral do candidato, não foram incluídas, o que pode limitar o poder preditivo dos modelos e afetar a interpretação das métricas de *fairness*.

Definição de grupos protegidos. A binarização da variável racial (branca vs. não-branca) simplifica a complexidade da autodeclaração racial no Brasil. Análises mais granulares por categoria (parda, preta, indígena, amarela) poderiam revelar padrões de disparidade não capturados pela agregação adotada.

Limiar de classificação. As métricas de *fairness* foram calculadas sobre predições binárias geradas por limiares τ^* otimizados por MCC. A análise de sensibilidade indicou que variações de $\pm 0{,}05$ no limiar produzem alterações moderadas nas métricas (até ΔDIR = 0,039), sugerindo que os resultados são razoavelmente robustos, mas não imunes à escolha do ponto de corte.

6. Conclusão e Trabalhos Futuros

Este estudo investigou empiricamente se a arquitetura de inferência bayesiana do TabPFN produz perfis de equidade algorítmica distintos do XGBoost na predição de resultados eleitorais municipais. A análise foi conduzida sobre 2.178 candidaturas a prefeito no Ceará entre 2012 e 2024, utilizando exclusivamente atributos sociodemográficos como preditores.

Os resultados confirmaram as três hipóteses formuladas:

- **H_1 (Paridade de Performance):** Confirmada. Ambos os modelos apresentaram desempenho preditivo estatisticamente equivalente (MCC $\approx$ 0,28; Wilcoxon $p = 1{,}000$; Cohen $d = 0{,}059$).
- **H_2 (Divergência de Equidade por Gênero):** Confirmada. O XGBoost apresentou DIR = 1,18 (IC-95%: [1,11; 1,24]), excluindo a neutralidade, enquanto o TabPFN manteve DIR = 1,01 (IC-95%: [0,85; 1,19]), sem evidência de disparidade significativa.
- **H_3 (Divergência de Equidade Racial):** Confirmada. O XGBoost apresentou DIR = 0,88 (IC-95%: [0,83; 0,92]), indicando subpredição para candidatos não-brancos, enquanto o TabPFN apresentou DIR = 0,91 (IC-95%: [0,80; 1,02]), sem disparidade estatisticamente significativa.

A principal contribuição deste trabalho é a demonstração empírica de que dois classificadores arquiteturalmente distintos podem atingir acurácia equivalente, mas produzir perfis de equidade mensuravelmente diferentes. Esse achado tem implicações práticas para a seleção de modelos em contextos sensíveis a *fairness*: a escolha entre XGBoost e TabPFN não é apenas técnica, mas carrega consequências éticas sobre quais padrões históricos o modelo irá reproduzir ou atenuar.

6.1. Trabalhos futuros

Diversas direções de pesquisa emergem dos resultados deste estudo:

1. **Extensão geográfica e temporal:** Replicar a análise para outros estados brasileiros e incluir eleições estaduais e federais, avaliando a generalização dos achados.
2. **Estratégias de *ensemble*:** Investigar se a combinação das predições de XGBoost e TabPFN pode melhorar simultaneamente o desempenho e a equidade, explorando a complementaridade evidenciada pelo teste de McNemar.
3. **Mecanismos causais:** Aplicar técnicas de interpretabilidade (SHAP, LIME) para identificar quais atributos contribuem para as disparidades observadas em cada modelo.
4. **Mitigação explícita de viés:** Comparar os resultados obtidos com versões dos modelos que incorporam restrições de *fairness* (FairXGBoost, FairPFN), avaliando o *trade-off* entre equidade e desempenho.

5. **Validação com dados completos de raça:** Repetir a análise excluindo o ciclo de 2012 ou utilizando apenas ciclos posteriores a 2016, quando a coleta de autodeclaração racial foi padronizada pelo TSE.

Referências

Alpaydin, E. (1999). Combined 5 $\times$ 2 cv f test for comparing supervised classification learning algorithms. *Neural Computation*, 11(8):1885–1892.

Base dos Dados (2026). Eleições brasileiras: Dados do tribunal superior eleitoral (TSE) tratados. `https://basedosdados.org`.

Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.

Chicco, D. and Jurman, G. (2020). The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics*, 21:6.

Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, 2nd edition.

Feldman, M., Friedler, S. A., Moeller, J., Scheidegger, C., and Venkatasubramanian, S. (2015). Certifying and removing disparate impact. In *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 259–268.

Garg, A. et al. (2025). Real-TabPFN: Improving tabular foundation models via continued pre-training with real-world data. *arXiv preprint*.

Grari, V., Ruf, B., Lamprier, S., and Detyniecki, M. (2020). Achieving fairness with decision trees: An adversarial approach. *Data Science and Engineering*, 5:99–110.

Hollmann, N., Müller, S., Eggensperger, K., and Hutter, F. (2022). TabPFN: A transformer that solves small tabular classification problems in a second. In *International Conference on Learning Representations (ICLR)*.

Kaufman, S., Rosset, S., Perlich, C., and Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4):1–21.

Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI)*, pages 1137–1143.

Miguel, L. F. and Biroli, F. (2010). Práticas de gênero e carreiras políticas: vertentes explicativas. *Revista Estudos Feministas*, 18(3):653–679.

Qu, J. et al. (2025). TabICL: A tabular foundation model for in-context learning on large data. *arXiv preprint*.

Ravichandran, S. et al. (2020). FairXGBoost: Fairness-aware classification in XGBoost. In *KDD Workshop on Machine Learning in Finance*.

Robertson, J. et al. (2024). FairPFN: Transformers can do counterfactual fairness. In *International Conference on Machine Learning (ICML)*.

Wikipedia Contributors (2025). TabPFN — Wikipedia, the free encyclopedia. https://en.wikipedia.org/wiki/TabPFN.